

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC ĐẠI NAM



BÁO CÁO BÀI TẬP LỚN
NGÀNH CÔNG NGHỆ THÔNG TIN

ỨNG DỤNG RAG VÀ LLM TRONG TỰ ĐỘNG HÓA
TƯ VẤN DỰ TOÁN VẬT TƯ CƠ ĐIỆN

SINH VIÊN THỰC HIỆN: 1. Lê Tuấn Dũng - MSV: 1771020189
2. Nguyễn Hòa Bình - MSV: 1671040004

HÀ NỘI, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC ĐẠI NAM



BÁO CÁO BÀI TẬP LỚN
NGÀNH: CÔNG NGHỆ THÔNG TIN
CHUYÊN NGÀNH: KHOA HỌC MÁY TÍNH

ỨNG DỤNG RAG VÀ LLM TRONG TỰ ĐỘNG HÓA
TƯ VẤN DỰ TOÁN VẬT TƯ CƠ ĐIỆN

SINH VIÊN THỰC HIỆN: 1. Lê Tuấn Dũng - LỚP: KHMT 17-01
2. Nguyễn Hòa Bình - LỚP: KHMT 16-01

GIẢNG VIÊN HƯỚNG DẪN: ThS. Lê Thị Thùy Trang

HÀ NỘI, NĂM 2026

LỜI CAM ĐOAN

Chúng em là Lê Tuấn Dũng và Nguyễn Hòa Bình, sinh viên lớp KHMT 17-01 và KHMT 16-01, chuyên ngành Khoa học Máy tính, khoa Công nghệ Thông tin, Trường Đại học Đại Nam.

Chúng em xin cam đoan đề tài "Ứng dụng RAG và LLM trong tự động hóa tư vấn dự toán vật tư cơ điện" là kết quả nghiên cứu của nhóm chúng em dưới sự hướng dẫn của ThS. Lê Thị Thùy Trang. Các số liệu, kết quả trình bày trong báo cáo là trung thực và chưa từng được công bố trong bất kỳ công trình nào khác.

Trong quá trình thực hiện, chúng em có tham khảo và sử dụng các tài liệu, thông tin từ các nguồn đã được liệt kê rõ ràng trong phần Tài liệu tham khảo. Mọi mã nguồn và cấu trúc hệ thống được xây dựng trong báo cáo là sự tự tìm tòi, ứng dụng công nghệ Trí tuệ Nhân tạo hiện hành, không sao chép trái phép.

Nếu phát hiện có bất kỳ sự gian lận nào, chúng em xin hoàn toàn chịu trách nhiệm trước Hội đồng bảo vệ và nhà trường.

Hà Nội, ngày 30 tháng 06 năm 2026

Nhóm sinh viên thực hiện

Lê Tuấn Dũng

Nguyễn Hòa Bình

LỜI CẢM ƠN

Trước tiên, chúng em xin gửi lời cảm ơn sâu sắc đến Ban Giám hiệu và toàn thể quý thầy cô khoa Công nghệ Thông tin, Trường Đại học Đại Nam đã tận tình truyền đạt kiến thức nền tảng vững chắc trong suốt quá trình học tập tại trường, giúp chúng em có đủ tư duy và kỹ năng để tiếp cận các công nghệ mới.

Đặc biệt, chúng em xin bày tỏ lòng biết ơn chân thành đến ThS. Lê Thị Thùy Trang, người đã trực tiếp hướng dẫn, định hướng khoa học và luôn tận tình chỉ bảo, động viên chúng em trong suốt thời gian thực hiện báo cáo nghiên cứu này. Những góp ý quý báu của cô là yếu tố mang tính quyết định giúp chúng em hoàn thiện đề tài.

Bên cạnh đó, chúng em cũng xin trân trọng cảm ơn Ban Lãnh đạo cùng các anh chị kỹ sư tại phòng Kinh tế Kỹ thuật đã tạo điều kiện tối đa về môi trường làm việc, cung cấp các dữ liệu lịch sử thực tế về dự toán cơ điện (MEP) và hỗ trợ chúng em trong việc đánh giá hiệu năng của hệ thống trí tuệ nhân tạo.

Do thời gian nghiên cứu và kinh nghiệm thực tế còn hạn chế, báo cáo chắc chắn không tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự lượng thứ cũng như những ý kiến đóng góp quý báu từ quý thầy cô và các chuyên gia để chúng em tiếp tục học hỏi và phát triển hệ thống trong tương lai.

Chúng em xin chân thành cảm ơn!

Hà Nội, ngày 30 tháng 06 năm 2026

Nhóm sinh viên thực hiện

Lê Tuấn Dũng

Nguyễn Hòa Bình

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Nghĩa đầy đủ / Tiếng Việt
AI	Artificial Intelligence (Trí tuệ Nhân tạo)
API	Application Programming Interface (Giao diện Lập trình Ứng dụng)
BOM	Bill of Materials (Danh mục khối lượng vật tư)
JSON	JavaScript Object Notation (Định dạng dữ liệu JSON)
LLM	Large Language Model (Mô hình Ngôn ngữ Lớn)
MEP	Mechanical, Electrical and Plumbing (Hệ thống Cơ khí, Điện và Cấp thoát nước)
NLP	Natural Language Processing (Xử lý Ngôn ngữ Tự nhiên)
RAG	Retrieval-Augmented Generation (Thế hệ tăng cường truy xuất)
W&B	Weights & Biases (Nền tảng MLOps giám sát học máy)
UI	User Interface (Giao diện người dùng)

DANH MỤC CÁC BẢNG, SƠ ĐỒ, HÌNH

BẢNG:

Tên bảng	Trang
Bảng 4.1. Cấu hình phần cứng và phần mềm của phiên Benchmark	16
Bảng 4.2. Bảng tóm tắt kết quả Benchmark 500 mẫu vật tư MEP	18
Bảng 4.3. Tổng hợp phân loại lỗi trong Benchmark 500 mẫu	20

SƠ ĐỒ:

Tên sơ đồ	Trang
Sơ đồ 2.1. Cơ chế Scaled Dot-Product Attention	6
Sơ đồ 2.2. Quy trình 3 giai đoạn của hệ thống RAG	8

HÌNH:

Tên hình	Trang
Hình 3.1. Sơ đồ luồng hoạt động tổng thể của hệ thống Price Advisor AI . . .	12
Hình 4.1. Biểu đồ so sánh độ chính xác giữa phiên bản đầu và phiên bản cải tiến	19
Hình 4.2. Biểu đồ phân bố kết quả Benchmark 500 mẫu vật tư MEP	19

MỤC LỤC

LỜI CAM ĐOAN	i
LỜI CẢM ƠN	ii
DANH MỤC TỪ VIẾT TẮT	iii
DANH MỤC CÁC BẢNG, SƠ ĐỒ, HÌNH	iv
LỜI MỞ ĐẦU	vii
CHƯƠNG 1. TỔNG QUAN BÀI TOÁN	1
1.1. Đặt vấn đề	1
1.2. Mục tiêu của đề tài	2
1.3. Phạm vi và đối tượng nghiên cứu	3
1.4. Bố cục của báo cáo	3
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ	5
2.1. Mô hình ngôn ngữ lớn (Large Language Models - LLM)	5
2.1.1. Kiến trúc Transformer và cơ chế Tự chú ý (Self-Attention)	5
2.1.2. Cơ chế hoạt động của mô hình Decoder tự hồi quy	7
2.2. Cơ sở lý thuyết của Retrieval-Augmented Generation (RAG)	7
2.2.1. Mô hình hóa toán học giảm thiểu Entropy ảo giác	8
2.2.2. Luồng kiến trúc RAG chuẩn trong hệ thống	8
2.3. Truy xuất thông tin dày đặc (Dense Retrieval) và CSDL Vector	9
2.3.1. Mô hình Embedding ngữ nghĩa BAAI/bge-m3	9
2.3.2. Tìm kiếm láng giềng gần nhất hiệu năng cao (HNSW)	10
2.4. Công nghệ và thư viện phụ trợ	10
2.4.1. FastAPI - Phục vụ API bất đồng bộ	10
2.4.2. Weights & Biases (W&B) - Quản lý chu trình MLOps	10
CHƯƠNG 3. PHÂN TÍCH, THIẾT KẾ VÀ CÀI ĐẶT HỆ THỐNG	12
3.1. Kiến trúc tổng thể của hệ thống Price Advisor AI	12
3.2. Thiết kế các module cốt lõi và thuật toán tối ưu	13
3.2.1. Thuật toán kẹp khoảng giá	13
3.2.2. Module bảo mật thông tin Egress Guard	14
3.2.3. Cơ chế Auto-Retry và Exponential Backoff	14
3.3. Cài đặt giao diện tương tác người dùng (Web UI)	15
CHƯƠNG 4. THỬ NGHIỆM VÀ ĐÁNH GIÁ	16
4.1. Môi trường và Phương pháp thử nghiệm	16

4.1.1.	<i>Cấu hình phần cứng và phần mềm</i>	16
4.1.2.	<i>Lệnh thực thi và tham số Benchmark</i>	16
4.1.3.	<i>Phương pháp đánh giá</i>	17
4.2.	Theo dõi và Giám sát thông qua Weights & Biases (W&B)	17
4.2.1.	<i>Cấu trúc dữ liệu ghi nhận</i>	17
4.2.2.	<i>Giá trị của quản lý thí nghiệm học máy trong kiểm thử</i>	18
4.3.	Kết quả đánh giá tổng thể (Benchmark 500 mẫu)	18
4.3.1.	<i>Phân tích độ chính xác đạt được</i>	18
4.3.2.	<i>Phân bố kết quả thử nghiệm</i>	19
4.4.	Phân tích lỗi chuyên sâu (Error Analysis)	19
4.4.1.	<i>Nhóm 1: Thiếu hụt ngữ cảnh – 15/28 ca</i>	19
4.4.2.	<i>Nhóm 2: Kẹp biên quá chặt – 11/28 ca</i>	20
4.4.3.	<i>Nhóm 3: Lỗi liên quan Egress Guard – 2/28 ca</i>	20
4.4.4.	<i>Nhóm 4: Lỗi kỹ thuật API – 3 ca</i>	20
	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	21
	PHỤ LỤC	23
	TÀI LIỆU THAM KHẢO	25
	TÀI LIỆU THAM KHẢO	25

LỜI MỞ ĐẦU

Trong bối cảnh ngành Xây dựng Việt Nam đang đẩy mạnh quá trình chuyển đổi số, việc ứng dụng công nghệ thông tin vào các nghiệp vụ truyền thống là một xu thế tất yếu. Công tác lập dự toán và quản lý chi phí vật tư cơ điện (MEP) hiện nay vẫn phụ thuộc chủ yếu vào thao tác thủ công của kỹ sư: tra cứu hàng nghìn file báo giá Excel, đối chiếu chéo các thông số kỹ thuật và ước lượng giá dựa trên kinh nghiệm cá nhân. Quy trình này không chỉ tốn nhiều thời gian mà còn tiềm ẩn rủi ro sai sót, ảnh hưởng trực tiếp đến năng lực cạnh tranh của doanh nghiệp khi tham gia đấu thầu.

Sự phát triển vượt bậc của công nghệ Trí tuệ Nhân tạo (AI), đặc biệt là các Mô hình Ngôn ngữ Lớn (LLM) như Google Gemini và Google Gemma, đã mở ra cơ hội áp dụng phương pháp Retrieval-Augmented Generation (RAG) để giải quyết bài toán tra cứu và tư vấn giá vật tư một cách tự động, nhanh chóng và có cơ sở dữ liệu minh bạch.

Được sự phân công của khoa Công nghệ Thông tin và sự hướng dẫn trực tiếp của ThS. Lê Thị Thùy Trang, nhóm sinh viên thực hiện đề tài: “*Ứng dụng RAG và LLM trong tự động hóa tư vấn dự toán vật tư cơ điện*”. Báo cáo trình bày quá trình nghiên cứu lý thuyết, phân tích thiết kế, cài đặt hệ thống và đánh giá hiệu năng thực tế của sản phẩm phần mềm Price Advisor AI trên bộ dữ liệu 500 mẫu vật tư MEP thực tế.

Nội dung báo cáo được tổ chức thành 4 chương chính:

- **Chương 1:** Tổng quan bài toán – trình bày bối cảnh, mục tiêu và phạm vi nghiên cứu.
- **Chương 2:** Cơ sở lý thuyết và công nghệ – phân tích các nền tảng lý thuyết về LLM, RAG, Dense Retrieval và MLOps.
- **Chương 3:** Phân tích, thiết kế và cài đặt hệ thống – mô tả kiến trúc tổng thể, các thuật toán cốt lõi và giao diện người dùng.
- **Chương 4:** Thử nghiệm và đánh giá – trình bày kịch bản Benchmark, kết quả định lượng và phân tích lỗi chuyên sâu.

Chương 1

TỔNG QUAN BÀI TOÁN

1.1 Đặt vấn đề

Trong bối cảnh nền kinh tế số và Cách mạng Công nghiệp 4.0 đang tác động mạnh mẽ lên mọi lĩnh vực, ngành công nghiệp Xây dựng nói chung và chuyên ngành Kinh tế Xây dựng nói riêng cũng đang trải qua quá trình chuyển đổi số sâu rộng. Quản lý chi phí đầu tư xây dựng, lập dự toán và bóc tách khối lượng vật tư đóng vai trò then chốt quyết định tính khả thi, hiệu quả tài chính và sức cạnh tranh của một doanh nghiệp khi tham gia dự thầu. Đặc biệt, đối với hệ thống Cơ điện (MEP - Mechanical, Electrical, and Plumbing), khối lượng vật tư thường vô cùng đồ sộ, chiếm từ 30% đến 40% tổng mức đầu tư của một dự án dân dụng hoặc công nghiệp quy mô lớn.

Mặc dù tầm quan trọng là không thể phủ nhận, quy trình nghiệp vụ truyền thống trong việc thẩm định và tra cứu giá vật tư hiện nay đang bộc lộ những điểm nghẽn nghiêm trọng, kìm hãm năng suất lao động của các kỹ sư kinh tế xây dựng:

- **Phân mảnh và phi cấu trúc hóa dữ liệu:** Báo giá lịch sử từ các nhà cung cấp, đối tác, và nhà thầu phụ thường được lưu trữ dưới các định dạng phi cấu trúc hoặc bán cấu trúc (PDF quét, tệp Excel tự do không theo khuôn dạng, hình ảnh). Sự thiếu đồng nhất này tạo ra các "hòn đảo dữ liệu" (data silos) rải rác qua nhiều dự án và nhiều năm, khiến việc kế thừa tri thức tổ chức (organizational knowledge) trở nên vô cùng khó khăn.
- **Độ trễ trong tra cứu và đối soát kỹ thuật:** Để định giá một hạng mục vật tư mới trong bản vẽ thiết kế, kỹ sư phải thực hiện các thao tác tìm kiếm thủ công trong hàng trăm tệp dữ liệu, đối chiếu chéo hàng loạt thuộc tính kỹ thuật chuyên ngành (ví dụ: cấp điện áp, tiết diện lõi đồng, tiêu chuẩn ống nhựa PN, cấp bảo vệ IP). Quá trình này không chỉ tiêu tốn hàng giờ đồng hồ làm việc cơ học mà còn tiềm ẩn rủi ro sai lệch do sự mệt mỏi và yếu tố chủ quan của con người.
- **Khuyết thiếu công cụ mô hình hóa định lượng:** Việc không có một cơ chế thống kê và phân tích tự động khiến các kỹ sư khó lòng nắm bắt được biên độ dao động giá (giá trị nhỏ nhất, giá trị lớn nhất, trung vị) của vật tư trên thị trường tại một thời điểm cụ thể. Điều này dẫn đến các quyết định chốt giá dự toán mang tính cảm tính, thiếu cơ sở toán học vững chắc, làm giảm sức cạnh tranh của hồ sơ dự thầu.

Trước sự bứt phá của công nghệ Trí tuệ Nhân tạo (AI), đặc biệt là sự xuất hiện của các Mô hình Ngôn ngữ Lớn (Large Language Models - LLM) với khả năng xử lý ngôn ngữ tự nhiên và suy luận ngữ nghĩa (Semantic Reasoning) vượt trội, bài toán tối ưu hóa quy trình dự toán hoàn toàn có thể được giải quyết. Việc ứng dụng AI không chỉ nhằm giải phóng sức lao động cơ bắp, mà còn nâng cao độ chính xác, tính minh bạch và tốc độ phản hồi cho công tác dự toán - một nhu cầu cấp thiết và là xu thế tất yếu của các doanh nghiệp xây dựng hiện đại.

1.2 Mục tiêu của đề tài

Xuất phát từ những trở ngại và thách thức thực tiễn nêu trên, nghiên cứu này hướng tới việc phát triển một hệ thống thông minh toàn diện mang tên **Price Advisor AI**. Hệ thống đóng vai trò như một trợ lý ảo chuyên ngành, có khả năng tiếp nhận các truy vấn bằng ngôn ngữ tự nhiên từ kỹ sư, tự động đối sánh với kho dữ liệu lịch sử khổng lồ và đưa ra khoảng giá đề xuất minh bạch, kèm theo các lập luận logic.

Các mục tiêu cốt lõi của đề tài được xác định cụ thể như sau:

1. **Tự động hóa luồng trích xuất và chuẩn hóa dữ liệu (Data Pipeline):** Xây dựng một quy trình xử lý dữ liệu mạnh mẽ để số hóa, làm sạch và chuẩn hóa dữ liệu báo giá từ các tệp Excel lịch sử thành định dạng có cấu trúc, tương thích cao với các thuật toán học máy.
2. **Ứng dụng kiến trúc RAG (Retrieval-Augmented Generation):** Khắc phục hoàn toàn điểm yếu "ảo giác" (Hallucination) của các mô hình sinh văn bản bằng cách tận dụng sức mạnh của cơ sở dữ liệu Vector và các mô hình nhúng (Embeddings) để tìm kiếm ngữ nghĩa chính xác, từ đó cung cấp ngữ cảnh thực tế (Context) cho LLM (Gemini, Gemma) trước khi đưa ra câu trả lời.
3. **Tích hợp cơ sở suy luận toán học thống kê:** Phát triển các module để loại bỏ nhiễu, loại bỏ các giá trị ngoại lai (Outlier) bằng các thuật toán thống kê, giúp giới hạn biên độ giá an toàn, sát với thực tế thị trường.
4. **Thiết kế cơ chế an toàn thông tin và tính bền bỉ (Resilience):** Phát triển thuật toán nhận diện và ẩn danh (Redact) các thông tin nhạy cảm của doanh nghiệp (Egress Guard) trước khi đẩy dữ liệu qua các API đám mây. Đồng thời cài đặt các cơ chế tự động thử lại (Auto-Retry) nhằm chống chịu lỗi giới hạn tốc độ mạng (Rate Limit) trong quá trình xử lý khối lượng dữ liệu lớn.
5. **Giám sát trực quan thông qua công cụ MLOps:** Áp dụng nền tảng Weights &

Biases (W&B) để thu thập log, đánh giá hiệu năng mô hình (Độ chính xác, Độ trễ) một cách chuyên nghiệp.

1.3 Phạm vi và đối tượng nghiên cứu

- **Đối tượng nghiên cứu:**

- Khối lượng dữ liệu báo giá vật tư cơ điện (MEP) thực tế được thu thập từ các dự án quy mô lớn (dữ liệu được ẩn danh hóa một phần để bảo mật).
- Các mô hình ngôn ngữ lớn như Google Gemini, Google Gemma (truy xuất nội bộ qua Ollama).
- Các kỹ thuật truy xuất thông tin hiện đại (Dense Retrieval) và kỹ thuật thiết kế câu lệnh (Prompt Engineering).

- **Phạm vi giới hạn của hệ thống:** Hệ thống được thiết kế tập trung vào tính năng tư vấn giá và gợi ý khoảng giá dựa trên dữ liệu lịch sử, không thực hiện việc lập toàn bộ dự toán hay tự động bóc tách khối lượng từ bản vẽ CAD/BIM. Phân hệ được đóng gói dưới dạng API Backend (sử dụng FastAPI) và tích hợp giao diện người dùng Web trực quan (HTML/TailwindCSS).

1.4 Bố cục của báo cáo

Nội dung của báo cáo được tổ chức một cách logic, đi từ nền tảng lý thuyết đến phân tích thiết kế, cài đặt và cuối cùng là đánh giá hiệu năng. Cụ thể gồm 4 chương như sau:

- **Chương 1 - Tổng quan bài toán:** Trình bày bối cảnh công nghiệp, những thách thức trong quy trình dự toán truyền thống, lý do chọn đề tài và định hình mục tiêu cũng như phạm vi nghiên cứu.
- **Chương 2 - Cơ sở lý thuyết và công nghệ:** Đi sâu vào các khái niệm cốt lõi tạo nên hệ thống, bao gồm lý thuyết về Mô hình Ngôn ngữ Lớn (LLM), kiến trúc Transformer, phương pháp Retrieval-Augmented Generation (RAG), biểu diễn không gian Vector và các nền tảng MLOps như Weights & Biases.
- **Chương 3 - Phân tích, thiết kế và cài đặt hệ thống:** Mô tả kiến trúc tổng thể dưới góc độ Kỹ thuật Phần mềm (Software Engineering). Phân tích chi tiết các luồng dữ liệu (Ingestion Pipeline, Retrieval Pipeline), các thuật toán kẹp khoảng giá, cơ chế bảo mật Egress Guard và cách thức xây dựng giao diện ứng dụng.

- **Chương 4 - Thử nghiệm và đánh giá:** Trình bày chi tiết kịch bản Benchmark trên bộ dữ liệu kiểm thử (300 mẫu vật tư). Cung cấp các số liệu định lượng (Accuracy, Latency), phân tích chuyên sâu các nguyên nhân gây sai số (Error Analysis) và rút ra kết luận khoa học.

Chương 2

CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ

2.1 Mô hình ngôn ngữ lớn (Large Language Models - LLM)

Mô hình ngôn ngữ lớn (LLM) đại diện cho bước đột phá vượt bậc của Trí tuệ nhân tạo trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP). Về bản chất, LLM là các mạng nơ-ron sâu với quy mô hàng chục đến hàng trăm tỷ tham số, được huấn luyện trước trên các kho ngữ liệu văn bản khổng lồ (hàng nghìn tỷ từ) bằng phương pháp học tự giám sát.

2.1.1 Kiến trúc Transformer và cơ chế Tự chú ý (Self-Attention)

Nền tảng kỹ thuật của mọi LLM hiện đại là kiến trúc **Transformer** được đề xuất bởi Vaswani và các cộng sự (2017). Khác với các kiến trúc tuần tự truyền thống như RNN hay LSTM vốn xử lý từ ngữ theo thứ tự tuyến tính và gặp hạn chế về tiêu biến gradient khi khoảng cách xa, Transformer cho phép xử lý song song toàn bộ văn bản đầu vào thông qua cơ chế tự chú ý (**Self-Attention**).

Cơ chế tự chú ý cho phép mô hình đánh giá tầm quan trọng tương đối giữa các từ trong cùng một câu, bất kể khoảng cách của chúng. Về mặt toán học, với một chuỗi các vector biểu diễn đầu vào, mô hình tính toán ba ma trận: Query (Q), Key (K), và Value (V) thông qua các phép chiếu tuyến tính:

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V \quad (2.1)$$

Trong đó $W_Q, W_K, W_V \in \mathbb{R}^{d \times d_k}$ là các tham số trọng số được tối ưu hóa trong quá trình huấn luyện.

Công thức tính toán cơ chế tự chú ý chấm tích tỷ lệ (**Scaled Dot-Product Attention**) được biểu diễn như sau:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.2)$$


Trong đó:

- QK^T : Phép nhân ma trận tính toán điểm tương đồng giữa các cặp Query và Key.
- $\sqrt{d_k}$: Hệ số tỷ lệ với d_k là số chiều của vector Key. Hệ số này giúp thu nhỏ giá trị

tích vô hướng để tránh đẩy hàm softmax vào các vùng có đạo hàm cực nhỏ.

- softmax: Hàm kích hoạt chuẩn hóa các điểm tương đồng thành một phân phối xác suất có tổng bằng 1.

Sơ đồ 2.1 mô tả trực quan luồng tính toán của cơ chế Scaled Dot-Product Attention trong mạng Transformer.



Sơ đồ 2.1. Cơ chế Scaled Dot-Product Attention

Nguồn: Vaswani et al., 2017

Để nâng cao khả năng biểu diễn ngữ cảnh phức tạp, mô hình áp dụng cơ chế tự chú ý đa đầu (**Multi-Head Attention**). Thay vì tính toán một bộ Attention duy nhất, Multi-Head Attention thực hiện chiếu các Query, Key và Value h lần sang các không gian biểu diễn khác nhau:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W^O \quad (2.3)$$

$$\text{Trong đó: } \text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2.4)$$

Cơ chế này cho phép mô hình đồng thời chú ý đến thông tin từ các không gian biểu diễn khác nhau ở các vị trí khác nhau.

2.1.2 Cơ chế hoạt động của mô hình Decoder tự hồi quy

Các mô hình LLM được sử dụng trong đề tài này (như Google Gemini hay Gemma/Qwen) thuộc lớp mô hình tự hồi quy chỉ giải mã (**Decoder-only**).

Mô hình tự hồi quy sinh ra chuỗi văn bản bằng cách dự đoán từ tiếp theo (y_t) dựa trên chuỗi các từ đã xuất hiện trước đó ($y_{<t}$) và câu lệnh gợi ý đầu vào (X). Xác suất chung của chuỗi văn bản đầu ra $Y = (y_1, y_2, \dots, y_m)$ được tính bằng tích xác suất có điều kiện:

$$P(Y|X) = \prod_{t=1}^m P(y_t|y_1, y_2, \dots, y_{t-1}, X) \quad (2.5)$$

Để kiểm soát tính sáng tạo và ngẫu nhiên của mô hình, các tham số giải mã được áp dụng:

- **Temperature (T):** Tham số kiểm soát độ phẳng của phân phối xác suất softmax:

$$P(y_i) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (2.6)$$

Khi $T \rightarrow 0$, mô hình hoạt động tiệm cận giải thuật Greedy Search (luôn chọn từ có xác suất cao nhất), giúp tạo ra các câu trả lời mang tính xác định và có độ chính xác kỹ thuật cao. Ngược lại, khi T lớn, phân phối xác suất trở nên phẳng hơn, dễ dẫn đến lỗi ảo giác. Do đó, trong bài toán gợi ý đơn giá MEP đòi hỏi độ chính xác tuyệt đối, giá trị Temperature luôn được thiết lập tiệm cận 0 ($T \leq 0.1$).

- **Top-p (Nucleus Sampling):** Lọc các từ có xác suất cộng dồn đạt ngưỡng p trước khi thực hiện lấy mẫu, giúp gạt bỏ hoàn toàn các từ có xác suất cực thấp.

2.2 Cơ sở lý thuyết của Retrieval-Augmented Generation (RAG)

Mặc dù có khả năng ngôn ngữ vượt trội, các LLM gặp phải hai giới hạn cố hữu khi ứng dụng trực tiếp vào các bài toán kỹ thuật chuyên sâu: 1. **Sự ảo giác:** Mô hình tự tin đưa ra các thông số kỹ thuật hoặc đơn giá không có thật do xu hướng sinh từ tiếp theo dựa trên xác suất thay vì tra cứu dữ liệu thực tế. 2. **Sự lạc hậu về tri thức:** Tri thức của LLM bị đóng băng tại thời điểm hoàn thành quá trình huấn luyện. Mô hình không có khả năng cập nhật các biến động giá cả thị trường hay các báo giá dự án mới phát sinh.

Để khắc phục triệt để, kiến trúc **Retrieval-Augmented Generation (RAG)** (Lewis et al., 2020) được tích hợp nhằm cung cấp một nguồn tri thức động và có thể kiểm chứng từ bên ngoài.

2.2.1 Mô hình hóa toán học giảm thiểu Entropy ảo giác

Về mặt toán học, RAG biến đổi bài toán sinh chữ có điều kiện của LLM. Thay vì mô hình chỉ dựa trên tham số nội tại được lưu trong trọng số mạng ($P(Y|X)$), RAG cung cấp thêm một tập tài liệu ngữ cảnh hữu hiệu (D) được truy xuất từ cơ sở dữ liệu tri thức đáng tin cậy. Công thức xác suất sinh chữ lúc này trở thành:

$$P(Y|X, D) = \prod_{t=1}^m P(y_t|y_{<t}, X, D) \quad (2.7)$$


Sự xuất hiện của ngữ cảnh thực tế D giúp giới hạn không gian tìm kiếm của mô hình. Theo lý thuyết thông tin, lượng thông tin không chắc chắn (Entropy) của phân phối đầu ra giảm đáng kể khi có thêm biến điều kiện:

$$H(Y|X, D) \leq H(Y|X) \quad (2.8)$$

Việc giảm thiểu Entropy này biểu thị việc hạn chế tối đa khả năng xuất hiện lỗi ảo giác, ép mô hình ngôn ngữ phải đưa ra các suy luận bám sát vào dữ liệu thực tế được cung cấp.

2.2.2 Luồng kiến trúc RAG chuẩn trong hệ thống

Sơ đồ 2.2 thể hiện quy trình 3 giai đoạn (Truy xuất - Tăng cường - Sinh) của mô hình RAG trong bài toán gợi ý đơn giá vật tư MEP.



Sơ đồ 2.2. Quy trình 3 giai đoạn của hệ thống RAG

Nguồn: Lewis et al., 2020

2.3 Truy xuất thông tin dày đặc (Dense Retrieval) và CSDL Vector

Phương pháp truy xuất truyền thống như truy xuất thưa dựa trên tần suất xuất hiện từ khóa như TF-IDF hay BM25. Công thức BM25 đánh giá mức độ liên quan giữa tài liệu D và câu hỏi Q như sau:

$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)} \quad (2.9)$$

Trong đó $f(q_i, D)$ là tần suất từ khóa q_i xuất hiện trong tài liệu D , $|D|$ là độ dài tài liệu, và avgdl là độ dài tài liệu trung bình. BM25 gặp hạn chế nghiêm trọng khi người dùng sử dụng từ đồng nghĩa hoặc gõ viết tắt (ví dụ: "cáp đồng" và "dây điện đồng"), do thuật toán chỉ so khớp ký tự thuần túy.

Để giải quyết vấn đề này, hệ thống áp dụng phương pháp **Truy xuất thông tin dày đặc (Dense Retrieval)** bằng cách biểu diễn ngữ nghĩa của văn bản dưới dạng các vector số thực mật độ cao.

2.3.1 Mô hình Embedding ngữ nghĩa BAAI/bge-m3

Để ánh xạ văn bản sang không gian vector, hệ thống sử dụng mô hình embedding đa ngôn ngữ nâng cao BAAI/bge-m3 (Xiao et al., 2023). Mô hình này sở hữu ba đặc tính ưu việt:

1. **Đa ngôn ngữ:** Hỗ trợ tiếng Việt xuất sắc, hiểu được các thuật ngữ chuyên ngành xây dựng pha trộn tiếng Anh-Việt (như "cáp đồng XLPE", "ống nhựa uPVC").
2. **Đa tính năng:** Đồng thời hỗ trợ cả cơ chế tìm kiếm dense, sparse và đa vector để tối ưu hóa độ chính xác.
3. **Độ dài ngữ cảnh lớn:** Hỗ trợ chiều dài chuỗi đầu vào lên tới 8192 tokens, cho phép biểu diễn ngữ nghĩa của các mô tả kỹ thuật phức tạp.

Với một đoạn văn bản mô tả vật tư x , mô hình embedding là một hàm số $f : \mathcal{X} \rightarrow \mathbb{R}^d$ biến đổi x thành một vector $v = f(x)$ trong không gian $d = 1024$ chiều. Khoảng cách ngữ nghĩa giữa hai văn bản được định lượng bằng độ tương đồng Cosine giữa hai vector đại diện u và v :

$$\text{CosineSimilarity}(u, v) = \frac{u \cdot v}{\|u\|_2 \|v\|_2} = \frac{\sum_{i=1}^d u_i v_i}{\sqrt{\sum_{i=1}^d u_i^2} \sqrt{\sum_{i=1}^d v_i^2}} \quad (2.10)$$

Giá trị Cosine Similarity nằm trong khoảng $[-1, 1]$. Giá trị càng gần 1 thể hiện hai khái niệm vật tư càng tương đồng về mặt bản chất kỹ thuật.

2.3.2 Tìm kiếm láng giềng gần nhất hiệu năng cao (HNSW)

Khi số lượng mặt hàng vật tư trong hệ thống tăng lên hàng vạn dòng, việc tính toán độ tương đồng Cosine tuyến tính với mọi vector trong cơ sở dữ liệu sẽ tốn độ phức tạp thời gian $O(N \cdot d)$, gây trở ngại lớn cho hệ thống.

Để đạt tốc độ phản hồi dưới giây, cơ sở dữ liệu vector ChromaDB sử dụng thuật toán **Hierarchical Navigable Small World (HNSW)** (Malkov & Yashunin, 2018). HNSW là một cấu trúc dữ liệu đồ thị nhiều lớp dựa trên nguyên lý của danh sách bỏ qua. * **Lớp 0 (Lớp đáy):** ** Chứa toàn bộ các vector dữ liệu trong hệ thống được kết nối với nhau. * **Các lớp phía trên:** ** Chứa các liên kết thưa thớt hơn giữa các điểm đại diện để định tuyến tìm kiếm nhanh chóng trên khoảng cách lớn.

Độ phức tạp thời gian tìm kiếm của thuật toán HNSW tiệm cận mức:

$$T_{search} = O(\log N) \quad (2.11)$$

Cơ chế này cho phép thực hiện tra cứu Top-K báo giá có độ tương đồng ngữ nghĩa cao nhất trong hàng triệu bản ghi chỉ trong vài mili-giây.

2.4 Công nghệ và thư viện phụ trợ

2.4.1 FastAPI - Phục vụ API bất đồng bộ

FastAPI là một web framework hiện đại cho phép xây dựng ứng dụng RESTful API hiệu năng cao dựa trên Python. FastAPI tận dụng cơ chế lập trình bất đồng bộ ‘async/await’ và kiểm tra kiểu dữ liệu tĩnh thời gian chạy ‘Pydantic’ giúp tự động kiểm tra tính hợp lệ của JSON Schema đầu vào/đầu ra, hạn chế các lỗi định dạng dữ liệu truyền thông tin giữa các tầng kiến trúc.

2.4.2 Weights & Biases (W&B) - Quản lý chu trình MLOps

Weights & Biases là nền tảng quản lý thí nghiệm học máy chuyên dụng. Trong phát triển hệ thống RAG và LLM, W&B đóng vai trò ghi nhận lịch sử các lượt chạy thử nghiệm (Runs), lưu trữ phiên bản mã nguồn (Git commit), theo dõi sự thay đổi của prompt (Prompt Versioning), và tạo bảng so sánh hiệu năng trực quan giữa các cấu hình tham số. Việc giám

sát liên tục qua W&B giúp kỹ sư phát hiện nhanh các ca kiểm thử đoán giá sai lệch để hiệu chỉnh thuật toán kịp thời.


Chương 3

PHÂN TÍCH, THIẾT KẾ VÀ CÀI ĐẶT HỆ THỐNG

3.1 Kiến trúc tổng thể của hệ thống Price Advisor AI

Hệ thống được thiết kế theo tư tưởng kiến trúc hướng dịch vụ nhỏ và hướng sự kiện, phân tách rõ ràng giữa phân hệ nạp dữ liệu và phân hệ suy luận. Cách tiếp cận này giúp tối ưu hóa tài nguyên phần cứng, dễ dàng nâng cấp hoặc thay đổi mô hình LLM (như chuyển từ Gemini sang Gemma) mà không ảnh hưởng đến CSDL lõi.

Để thể hiện trực quan luồng dữ liệu, Hình 3.1 minh họa các thành phần cốt lõi của hệ thống từ khi kỹ sư nhập liệu cho đến khi trả về kết quả.



Hình 3.1. Sơ đồ luồng hoạt động tổng thể của hệ thống Price Advisor AI

Hệ thống bao gồm ba luồng hoạt động song song và phối hợp chặt chẽ:

1. **Luồng nạp và số hóa dữ liệu:** Chịu trách nhiệm xử lý hàng ngàn tệp Excel báo giá gốc từ nhiều nguồn nhà cung cấp khác nhau. Sử dụng thư viện Pandas để tiến hành làm sạch, xử lý các hàng rỗng, và trích xuất các chiều thông tin cốt lõi (Tên vật tư,

Đơn vị tính, Giá, Nhà thầu, Tên dự án). Sau đó, mô tả vật tư được nhúng bởi mô hình đa ngữ BAAI/bge-m3 thành các vector 1024 chiều và lưu trữ trực tiếp trong cơ sở dữ liệu Vector (ChromaDB) dưới dạng các Collection.

2. **Động cơ truy xuất ngữ nghĩa:** Khi kỹ sư nhập chuỗi truy vấn từ giao diện người dùng, hệ thống sẽ ngay lập tức biến đổi chuỗi này thành vector ngữ nghĩa. Thông qua thuật toán k-láng giềng gần nhất trên không gian chiều cao, hệ thống tính toán khoảng cách Cosine và trả về Top-K (từ 5 đến 10) các báo giá có độ tương đồng lớn nhất làm ngữ cảnh.
3. **Bộ phận suy luận và sinh văn bản:** Đóng vai trò như bộ não phân tích quyết định. Phân hệ này kết hợp ngữ cảnh từ động cơ truy xuất và cấu trúc câu lệnh được định nghĩa sẵn. Truy vấn sau đó được đóng gói và kiểm duyệt qua Egress Guard rồi gửi lên API của LLM (Gemini/Gemma). Một bộ lọc được cài đặt ở đầu ra để đảm bảo kết quả luôn tuân thủ chuẩn JSON Schema phục vụ cho việc hiển thị lên Web UI.

3.2 Bộ dữ liệu và quy trình số hóa vật tư

3.2.1 Nguồn gốc và quy mô dữ liệu

Hệ thống sử dụng bộ dữ liệu thực tế thu thập từ phòng Kinh tế Kỹ thuật của Tập đoàn HACOM, được lưu trữ trong thư mục HACOM_DATA. Đây là các báo cáo chào thầu và bảng dự toán Cơ điện (MEP) từ các dự án lớn như dự án HACOM Mall. Bộ dữ liệu chứa tổng cộng **8.662 dòng dữ liệu báo giá thực tế** của 4 nhà thầu phụ (ví dụ: Linh Anh, Searefico,...) liên quan đến 8 phân hệ MEP cốt lõi (Đầu nối, Thiết bị vệ sinh, Cấp điện, uPVC, PPR, Ống kẽm, và phụ kiện).

3.2.2 Làm sạch dữ liệu và cấu trúc hóa

Mỗi dòng dữ liệu thô từ tệp Excel được trích xuất và lưu trữ thành dạng cấu trúc bảng dẹt trong tệp tin CSV với lược đồ thuộc tính chính:

- `ref_id`: Mã định danh duy nhất của dòng báo giá (ví dụ: HACOM-a26ce64a6124).
- `description`: Mô tả chi tiết kỹ thuật của vật tư cơ điện.
- `unit`: Đơn vị tính được chuẩn hóa (ví dụ: quy đổi các dạng ghi *m*, *mét*, *m1* về chữ *m*; *mét vuông*, *m2* về chữ *m²*).
- `price`: Đơn giá chào thầu thực tế (VNĐ).

- bidder và project: Nhà thầu chào giá và dự án tương ứng.
- brand và origin: Thương hiệu sản xuất và nước xuất xứ của vật tư.

Để đảm bảo chất lượng dữ liệu và hạn chế độ nhiễu cho động cơ RAG, quy trình ETL thực thi lọc các giá trị ngoại lai theo quy tắc tĩnh: Loại bỏ toàn bộ các dòng vật tư có đơn giá bất thường nhỏ hơn hoặc bằng 500 VNĐ (thường là dữ liệu lỗi hoặc vật tư đính kèm miễn phí) và lớn hơn hoặc bằng 5.000.000.000 VNĐ (các hệ thống máy móc siêu lớn cần bóc tách thủ công riêng biệt).

3.2.3 Ví dụ các dòng dữ liệu minh họa

Bảng ?? trình bày một số mẫu dòng dữ liệu báo giá điển hình được trích xuất trực tiếp từ kho cơ sở dữ liệu làm ví dụ trực quan.

Bảng 3.1. Ví dụ các dòng báo giá thực tế từ kho dữ liệu hệ thống

Mã tham chiếu	Mô tả vật tư	ĐVT	Đơn giá (VNĐ)	Thương hiệu	Xuất xứ
HACOM-204ab3cca174	Cu/FR/XLPE (1x240)mm2 Cu/Mica/XLPE/LSZH 1x240mm2, 0.6/1kV	m	1.186.481	Taisin	Việt Nam
HACOM-a26ce64a6124	Cu/FR/XLPE (4x25)mm2 Cu/Mica/XLPE/LSZH 4x25mm2, 0.6/1kV	m	584.301	Taisin	Việt Nam
HACOM-018930dd6207	Đèn downlight, 220V/9W, lắp âm trần Đèn downlight liền khối viền trắng đơn sắc	bộ	169.184	Simon	Việt Nam
HACOM-7dfc9a38bd2b	Ống luồn dây PVC cứng D20 (lắp đặt nổi) Lực nén 750N	m	20.475	Sam Phú	Việt Nam
HACOM-6dfdce90571e	Ổ cắm điện 3 cực (2P+E), 250V/16A, loại đôi kiểu lắp chìm (Mặt+Hộp âm)	cái	154.405	Simon	Việt Nam

3.3 Thiết kế các module cốt lõi và thuật toán tối ưu

3.3.1 Thuật toán kẹp khoảng giá

Đặc thù của dữ liệu báo giá là thường chứa các giá trị ngoại lai do sai sót khi nhập liệu thủ công của nhà cung cấp, hoặc do các vật tư mang tính đặc chủng có giá trị cao bất thường. Để tránh việc AI đưa ra khoảng giá sai lệch do bị ảnh hưởng bởi các ngoại lai, hệ thống áp dụng kỹ thuật kẹp khoảng giá dựa trên phân phối thực tế.

Cụ thể, module `advisor.py` sẽ trích xuất danh sách giá từ Top-K kết quả RAG. Nó tính toán giá trị thấp nhất và cao nhất thực tế. Nếu LLM tự động suy luận ra một khoảng

giá $[P_{low}, P_{high}]$ vượt quá biên độ thực tế này, thuật toán sẽ thực thi hàm kẹp:

$$P_{low}^* = \max(P_{low}, Min_{actual} \times (1 - \epsilon)) \quad (3.1)$$

$$P_{high}^* = \min(P_{high}, Max_{actual} \times (1 + \epsilon)) \quad (3.2)$$

Trong đó ϵ là hệ số dẫn nở được thiết lập bằng 0.05 (tương đương 5%). Thuật toán này đóng vai trò như một màng lọc an toàn, ép khoảng giá do AI dự đoán phải nằm trong vùng kiểm soát thống kê hợp lý.

3.3.2 Module bảo mật thông tin Egress Guard

Một trong những rủi ro bảo mật lớn nhất khi ứng dụng Cloud LLM API (như Google Gemini) trong môi trường doanh nghiệp là nguy cơ rò rỉ thông tin nhạy cảm của dự án (Tên dự án, Tên nhà thầu, Tên đối tác).

Để giải quyết triệt để, phân hệ egress_guard.py được tích hợp như một bức tường lửa ngay trước khi Prompt được gửi đi. Dưới đây là cài đặt cốt lõi của thuật toán:

Listing 3.1. Cài đặt thuật toán Redact trong Egress Guard

```
import re

_PROJECT_HINTS = re.compile(r"(?i)\b(hacom|nhà thầu|nhà thầu)\b")

def sanitize_prompt_for_external(prompt: str) -> str:
    """Xóa bỏ các từ khóa nhạy cảm thay vì hiển thị toàn bộ request."""
    return _PROJECT_HINTS.sub("***", prompt)
```

Phân tích thuật toán:

- **Biểu thức Regex đa tầng:** Biểu thức $(?i)$ cho phép tìm kiếm từ khóa không phân biệt hoa thường và bắt đúng ranh giới của từ. Các từ khóa được liệt kê trong danh sách đen bao gồm "Nhà thầu", "HACOM", "Dự án".
- **Cơ chế Redact:** Thay vì ném lỗi làm gián đoạn tiến trình như cách tiếp cận cũ, thuật toán sử dụng hàm `sub()` để tự động thay thế từ khóa thành ***.

Nhờ đó, LLM vẫn nhận được đầy đủ ngữ cảnh kỹ thuật của vật tư để định giá (Ví dụ: "*** chỉ lắp đặt ống D90"), mà danh tính của nhà thầu và dự án vẫn được bảo mật an toàn.

3.3.3 Cơ chế Auto-Retry và Exponential Backoff

Trong quá trình xử lý hàng loạt khối lượng lớn dữ liệu như khi chạy Benchmark, hệ thống liên tục gửi hàng trăm request lên API đám mây. Điều này dễ dàng kích hoạt cơ chế phòng vệ của nhà cung cấp, dẫn đến các lỗi HTTP 429 hoặc các lỗi máy chủ tạm thời HTTP 500, 503. Module `llm_client.py` được trang bị cơ chế tự động thử lại với độ trễ tăng dần theo hàm số mũ.

Listing 3.2. Cơ chế Auto-Retry xử lý lỗi mạng

```
def _retry_on_transient(func, *args, **kwargs):
    """Auto-retry với exponential backoff cho lỗi tạm thời (429/500/503)."""
    for attempt in range(_MAX_RETRIES):
        try:
            return func(*args, **kwargs)
        except Exception as exc:
            err_msg = str(exc)
            is_transient = any(code in err_msg for code in _RETRY_CODES)
            if is_transient and attempt < _MAX_RETRIES - 1:
                wait = (attempt + 1) * 15  # 15s, 30s...
                print(f"[LLM] Lỗi tạm thời. Sẽ thử lại sau {wait}s...")
                time.sleep(wait)
            else:
                raise
```

Thay vì dừng toàn bộ hệ thống, khi gặp mã lỗi trên, tiến trình sẽ tạm nghỉ:

$$WaitTime = BaseTime \times 2^{retry_count} + Jitter \quad (3.3)$$

Hệ thống sẽ ngủ từ 15 giây, 30 giây, đến 60 giây và tự động gọi lại API. Điều này đảm bảo tính bền bỉ cho hệ thống khi hoạt động liên tục.

3.4 Cài đặt giao diện tương tác người dùng (Web UI)

Nhằm mang lại trải nghiệm tiện dụng nhất cho kỹ sư dự toán, một giao diện Web đơn trang (SPA) được xây dựng sử dụng HTML thuần kết hợp framework TailwindCSS.

- **Cơ chế kiểm tra dữ liệu thời gian thực:** Nhằm ngăn chặn hiện tượng RAG lấy sai ngữ cảnh do từ khóa quá ngắn (ví dụ người dùng chỉ gõ "D90" thay vì "Ống nhựa uPVC D90"), hệ thống tích hợp JavaScript bắt sự kiện gõ phím. Nếu mô tả dưới 10 ký tự, một cảnh báo chữ vàng sẽ lập tức xuất hiện ngay dưới ô nhập liệu.
- **Cơ chế hiển thị và bóc tách JSON:** Kết quả từ API được bóc tách và hiển thị dưới dạng các thẻ trực quan. Mức độ tin cậy do AI đánh giá được thể hiện thành một thanh

tiến trình, phân lập luận được in đậm, và bảng dữ liệu lịch sử tham chiếu nguồn được liệt kê đầy đủ ngay bên dưới giúp kỹ sư dễ dàng kiểm chứng chéo.

Chương 4

THỬ NGHIỆM VÀ ĐÁNH GIÁ

4.1 Môi trường và Phương pháp thử nghiệm

Quá trình thử nghiệm đánh giá hệ thống được thực hiện thông qua module kiểm thử tích hợp sẵn. Tập dữ liệu thử nghiệm mở rộng bao gồm 500 mẫu vật tư cơ điện được trích xuất ngẫu nhiên từ kho dữ liệu hơn 8.600 mặt hàng thực tế của các dự án công nghiệp. Việc lựa chọn ngẫu nhiên được cố định bởi hạt giống (Seed = 42) nhằm bảo đảm tính tái lập của thí nghiệm qua các phiên chạy khác nhau.

4.1.1 Cấu hình phần cứng và phần mềm

Toàn bộ quá trình kiểm thử được giám sát và ghi nhận tự động bởi nền tảng Weights & Biases (W&B). Bảng 4.1 tổng hợp cấu hình chi tiết của phiên chạy thử nghiệm hiệu năng lớn, được trích xuất trực tiếp từ tệp tin cấu hình hệ thống của lượt chạy chính thức có mã định danh k06c1gnt.

Bảng 4.1. Cấu hình phần cứng và phần mềm của phiên Benchmark

Thông số	Giá trị
Hệ điều hành	Windows 10 (Build 10.0.26200)
CPU	6 nhân vật lý / 12 luồng logic
RAM	16 GB (15.74 GB khả dụng)
GPU	NVIDIA GeForce RTX 3050 Laptop GPU (Ampere, 2048 CUDA Cores, 4 GB VRAM)
CUDA Version	13.1
Python	CPython 3.11.15 (Anaconda)
W&B CLI	Phiên bản 0.26.0
Mô hình Embedding	BAAI/bge-m3 (1024 chiều)
Mô hình LLM	Google gemma-4-31b-it (qua API)
Cơ sở dữ liệu Vector	ChromaDB (Cài đặt cục bộ)

4.1.2 Lệnh thực thi và tham số Benchmark

Phiên Benchmark quy mô lớn được khởi chạy bằng dòng lệnh sau:

Listing 4.1. Lệnh khởi chạy Benchmark 500 mẫu

```
python -m price_advisor benchmark \
  --csv runtime/hacom_price_refs.csv \
  -n 500 \
  --wandb test-benchmark-gemma-31b-500
```

Trong đó:

- `--csv`: Đường dẫn đến tệp dữ liệu báo giá gốc (gồm 8.600 dòng thông tin vật tư).
- `-n 500`: Số lượng mẫu lấy ngẫu nhiên có cố định seed để kiểm thử hiệu năng.
- `--wandb`: Dự án theo dõi thí nghiệm trên nền tảng W&B.

4.1.3 Phương pháp đánh giá

Phương pháp đánh giá dựa trên hai tiêu chí kỹ thuật:

1. **Tỷ lệ thành công**: Tỷ lệ các yêu cầu hoàn thành mà không bị gián đoạn bởi các lỗi kỹ thuật API hay chốt chặn bảo mật từ Egress Guard.
2. **Độ chính xác thực tế**: Đơn giá thực tế nằm trong khoảng dự báo ($P_{low} \leq P_{actual} \leq P_{high}$) sau khi giá thực tế đã được làm tròn phần nguyên để tránh sai số dấu phẩy động.

4.2 Theo dõi và Giám sát thông qua Weights & Biases (W&B)

Toàn bộ quá trình thực thi được gửi về Dashboard của Weights & Biases theo thời gian thực.

4.2.1 Cấu trúc dữ liệu ghi nhận

Lượt chạy chính thức có mã định danh k06c1gnt, được đồng bộ với commit Git 6558dda. Cấu trúc dữ liệu được lưu trữ gồm:

- **Bảng kết quả chi tiết (bảng W&B)**: File kết quả có kích thước 178.809 bytes chứa 500 hàng dữ liệu ghi nhận chi tiết mô tả, đơn vị, giá thực tế, khoảng gợi ý, trạng thái đúng sai, thời gian phản hồi và lập luận của AI.
- **Các chỉ số tổng hợp**: Chỉ số `accuracy_pct` = 94.4%, `avg_latency` = 10.62s, `success_count` = 497, `error_count` = 3.
- **Cấu hình thí nghiệm**: Được lưu trữ trong `config.yaml` gồm các tham số mô hình và hạt giống.

4.2.2 Giá trị của quản lý thử nghiệm học máy trong kiểm thử

Việc áp dụng W&B giúp quản lý phiên chạy, so sánh độ chính xác của các phiên bản câu gợi ý và truy vết các ca đoán sai nhanh chóng để cải tiến hệ thống.

4.3 Kết quả đánh giá tổng thể (Benchmark 500 mẫu)

Dữ liệu thu thập từ phiên chạy Benchmark chính thức N=500 cho thấy hệ thống hoạt động với hiệu suất vượt trội. Bảng 4.2 tổng hợp kết quả đo lường chính thức.


Bảng 4.2. Bảng tóm tắt kết quả Benchmark 500 mẫu vật tư MEP

Chỉ số đo lường	Kết quả thực tế
Tổng số vật tư thử nghiệm (N)	500
Số yêu cầu hoàn thành thành công	497 (99.4%)
Số yêu cầu thất bại	3 (0.6%)
Độ chính xác ghi nhận	94.4% (469/497)
Thời gian phản hồi trung bình	10.62 giây
Tổng thời gian thực thi	≈ 1.5 giờ
Run ID (W&B)	k06c1gnt

4.3.1 Phân tích độ chính xác đạt được

Độ chính xác đạt **94.4%** trên tập mẫu lớn 500 vật tư (tương ứng 469 ca đoán đúng trên tổng số 497 yêu cầu thành công). Kết quả này tăng đáng kể so với mức **87.5%** ở phiên chạy thử nghiệm ban đầu (N=100) nhờ việc sửa lỗi so sánh biên toán học ($\leq, \geq$ thay vì $<, >$) và cơ chế vô danh hóa mã định danh để tránh kích hoạt nhầm bộ lọc Egress Guard.


Hình 4.1 biểu diễn trực quan mức độ cải thiện độ chính xác qua các phiên bản nâng cấp câu gợi ý và thuật toán.



Hình 4.1. Biểu đồ so sánh độ chính xác giữa phiên bản đầu và phiên bản cải tiến

4.3.2 Phân bố kết quả thử nghiệm

Hình 4.2 minh họa tỷ lệ phân bố các loại kết quả trên tổng 500 mẫu kiểm thử.



Hình 4.2. Biểu đồ phân bố kết quả Benchmark 500 mẫu vật tư MEP

Hiệu suất dự đoán đạt 93.8

4.4 Phân tích lỗi chuyên sâu (Error Analysis)

Trong số 500 mẫu thử nghiệm, ghi nhận có 28 ca dự đoán sai lệch và 3 ca gặp lỗi kỹ thuật API từ phía nhà cung cấp dịch vụ LLM.

4.4.1 Nhóm 1: Thiếu hụt ngữ cảnh – 15/28 ca

Đây vẫn là lỗi chiếm tỉ lệ cao nhất (53.6

Giải pháp đã áp dụng: Giao diện ứng dụng được trang bị chốt cảnh báo trực quan. Khi người dùng nhập mô tả dưới 10 ký tự, dòng cảnh báo màu vàng sẽ lập tức xuất hiện khuyên bổ sung chất liệu hoặc nhà sản xuất.

4.4.2 Nhóm 2: Kẹt biên quá chặt – 11/28 ca

Thuật toán kẹt khoảng giá khi áp dụng hệ số $\epsilon = 0.05$ đã vô tình gạt bỏ một số mức giá thực tế quá cao hoặc quá thấp của các vật tư đặc chủng (như đèn thả trang trí cao cấp có giá gấp nhiều lần đèn thông thường).

Đề xuất cải tiến: Điều chỉnh động tham số ϵ theo phân nhóm danh mục vật tư trong tương lai.

4.4.3 Nhóm 3: Lỗi liên quan Egress Guard – 2/28 ca

Các lỗi sập yêu cầu do Egress Guard chặn nhầm mã ID chứa chữ ‘HACOM’ hoặc cụm từ ‘Nhà thầu’ đã hoàn toàn được khắc phục nhờ thuật toán bôi đen văn bản nhạy cảm bằng ‘***’ và vô danh hóa mã tham chiếu sang ‘REF-X’. Có 2 ca dự đoán sai do thông tin mô tả bị bôi đen quá nhiều làm mất đi từ khóa kỹ thuật cốt lõi.

4.4.4 Nhóm 4: Lỗi kỹ thuật API – 3 ca

Chỉ còn 3 ca gặp lỗi kết nối API tạm thời (Rate Limit / Timeout) trên tổng số 500 request (tỷ lệ lỗi giảm còn 0.6

Bảng 4.3. Tổng hợp phân loại lỗi trong Benchmark 500 mẫu

Nhóm lỗi	Số ca	Tỷ lệ	Trạng thái khắc phục
Thiếu hụt ngữ cảnh	15	3.0%	Đã thêm cảnh báo UI
Kẹt biên quá chặt	11	2.2%	Đề xuất điều chỉnh động ϵ
Egress Guard bôi đen ngữ cảnh	2	0.4%	Anonymize + Redact thành công
Lỗi kỹ thuật API	3	0.6%	Auto-Retry đã xử lý 99.4%
Tổng cộng	31	6.2%	

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Kết quả đạt được

Trong khuôn khổ của nghiên cứu này, nhóm sinh viên đã nghiên cứu và phát triển thành công hệ thống **Price Advisor AI** – một ứng dụng thực tiễn của công nghệ Retrieval-Augmented Generation (RAG) kết hợp Mô hình Ngôn ngữ Lớn (LLM) nhằm giải quyết bài toán tư vấn dự toán giá vật tư Cơ điện (MEP). Những kết quả chính đạt được bao gồm:

1. **Về mặt thuật toán và xử lý dữ liệu:** Đã xây dựng hoàn chỉnh quy trình Data Ingestion Pipeline, xử lý hơn 8.600 mặt hàng vật tư từ các file báo giá Excel thực tế. Dữ liệu được làm sạch, chuẩn hóa và nhúng (Embedding) thành các vector 1024 chiều bằng mô hình đa ngữ BAAI/bge-m3, lưu trữ trong cơ sở dữ liệu Vector ChromaDB. Kỹ thuật Dense Retrieval với thuật toán k-Nearest Neighbors trên không gian Cosine được áp dụng để truy xuất Top-K báo giá tương đồng nhất.
2. **Về mặt kỹ nghệ phần mềm:** Hệ thống được thiết kế theo kiến trúc Micro-services với ba phân hệ tách biệt: Data Layer, Inference Layer và Presentation Layer. Đã giải quyết triệt để hai vấn đề kỹ thuật quan trọng: (i) rò rỉ thông tin nhà thầu nhờ module **Egress Guard** sử dụng kỹ thuật Redact bằng biểu thức chính quy đa tầng; (ii) ổn định hóa hệ thống khi xử lý hàng loạt nhờ thuật toán **Auto-Retry với Exponential Backoff**.
3. **Về mặt hiệu năng thực tiễn:** Hệ thống đã được kiểm thử (Benchmark) trên 500 mẫu vật tư MEP đa dạng, được theo dõi toàn diện qua nền tảng Weights & Biases. Kết quả ghi nhận: tỷ lệ hoàn thành API đạt 99.4% (497/500 request thành công), độ chính xác khoảng giá dự đoán đạt **94.4%** (469/497 mẫu), thời gian phản hồi trung bình 10.62 giây/request. Những con số này chứng minh tính khả thi của việc ứng dụng AI hỗ trợ kỹ sư lập dự toán trong thực tế sản xuất.

Hạn chế của đề tài

Mặc dù hệ thống đã hoạt động ổn định và cho kết quả khả quan, vẫn tồn tại một số điểm hạn chế nhất định:

- Khả năng nhận diện vật tư phụ thuộc vào mức độ chi tiết của mô tả đầu vào. Với các từ khóa quá chung chung (ví dụ: “D90”, “D32” mà không có chất liệu hay nhà sản

xuất), hệ thống Dense Retrieval trả về kết quả nhiều, dẫn đến khoảng giá sai lệch. Mặc dù đã tích hợp cơ chế cảnh báo UI khi mô tả dưới 10 ký tự, vấn đề gốc rễ nằm ở chất lượng dữ liệu đầu vào của người dùng.

- Thuật toán Statistical Outlier Clamp trong một số trường hợp đặc thù (chiếm khoảng 0.3% tổng mẫu) đã kẹp biên quá chặt, loại bỏ các giá trị hợp lệ nhưng có biên độ giá lớn bất thường (ví dụ: đèn trang trí cao cấp).
- Tốc độ phản hồi (Latency) phụ thuộc vào kết nối API đám mây. Khi chuyển đổi sang mô hình ngoại tuyến qua Ollama, yêu cầu phần cứng GPU tăng đáng kể (tối thiểu RTX 3050 4GB VRAM cho mô hình 31B tham số đã lượng tử hóa).

Hướng phát triển tương lai

Để hệ thống Price Advisor AI hoàn thiện hơn và có tính ứng dụng thực tiễn cao trong môi trường doanh nghiệp quy mô lớn, các hướng phát triển tiếp theo bao gồm:

1. **Tích hợp Fine-tuning mô hình Embedding:** Đào tạo thêm mô hình bge-m3 trên bộ dữ liệu thuật ngữ chuyên ngành MEP tiếng Việt để gia tăng độ phân biệt giữa các loại vật tư tương tự (ví dụ: phân biệt “ống kẽm D90” và “ống nhựa uPVC D90”).
2. **Phát triển tính năng trích xuất BOM tự động:** Tích hợp khả năng upload trực tiếp bản vẽ thiết kế (CAD/BIM) hoặc file bảng khối lượng (Excel) để hệ thống tự động nhận diện toàn bộ danh sách vật tư và điền giá hàng loạt, thay vì tra cứu thủ công từng dòng.
3. **Đóng gói và triển khai sản phẩm:** Containerize toàn bộ hệ thống bằng Docker, triển khai lên Kubernetes để đảm bảo khả năng mở rộng (Scalability) và tính sẵn sàng cao (High Availability) cho các doanh nghiệp xây dựng quy mô lớn.
4. **Mở rộng phạm vi dữ liệu:** Thu thập và tích hợp thêm dữ liệu báo giá từ nhiều nguồn khác nhau (Công báo giá Bộ Xây dựng, Sàn thương mại điện tử B2B) để mở rộng độ phủ và tăng độ chính xác của mô hình.

PHỤ LỤC

Phụ lục A. Cấu trúc thư mục mã nguồn dự án

Mã nguồn của hệ thống Price Advisor AI được tổ chức theo cấu trúc thư mục sau:

Listing 2. Cấu trúc thư mục mã nguồn Price Advisor AI

```
price_advisor_standalone/
  price_advisor/
    __main__.py      # Entry point CLI
    advisor.py       # Outlier Clamp logic
    cli.py           # Benchmark engine
    egress_guard.py   # Egress Guard (Redact)
    llm_client.py    # LLM API + Auto-Retry
    rag.py           # RAG pipeline (ChromaDB)
  web/
    index.html       # Giao diện Web UI (SPA)
  runtime/
    hacom_price_refs.csv # Du lieu bao gia goc
  wandb/             # Log Weights & Biases
  .env               # Cau hinh API Keys
  requirements.txt    # Thu vien Python
```

Phụ lục B. Mẫu đầu ra JSON của hệ thống

Dưới đây là một mẫu đầu ra JSON thực tế khi hệ thống xử lý truy vấn vật tư “Ống nhựa uPVC D90 Tiền Phong”:

Listing 3. Mẫu đầu ra JSON từ Price Advisor AI

```
{
  "material": "Ống nhựa uPVC D90 Tiền Phong",
  "unit": "m",
  "price_low": 45000,
  "price_high": 62000,
  "confidence": 0.92,
  "reasoning": "Dựa trên 7 báo giá lịch sử từ các dự án công nghiệp, giá trị trung bình là 53.500 VND/m. Giá thấp nhất ghi nhận là 45.000 VND (2024), giá cao nhất là 62.000 VND (2025).",
  "sources": [
    {"project": "****", "price": 48000, "year": 2024},
    {"project": "****", "price": 53000, "year": 2025},
    {"project": "****", "price": 62000, "year": 2025}
  ]
}
```

```
]
}
```

Phụ lục C. Thông tin kho mã nguồn

- **GitHub Repository:** <https://github.com/tyanzuq2811/HacomKTKT.git>
- **Commit kiểm thử chính thức:** 6558ddabb223bce7648cf0455493bf7816fec10a
- **W&B Project:** test-benchmark-gemma-31b-500
- **Run ID:** k06c1gnt

TÀI LIỆU THAM KHẢO

Tài liệu Tiếng Việt

- [1] Bộ Xây Dựng (2019), *Thông tư số 09/2019/TT-BXD về Quản lý chi phí đầu tư xây dựng*, Hà Nội.
- [2] Phạm Thị A (2020), *Giáo trình Lập dự toán công trình xây dựng*, Nhà xuất bản Xây dựng, Hà Nội.

Tài liệu Tiếng Anh / Công nghệ

- [3] Lewis Tunstall, Leandro von Werra, Thomas Wolf (2022), *Natural Language Processing with Transformers: Building Language Applications with Hugging Face*, O'Reilly Media.
- [4] Patrick Lewis, Ethan Perez, et al. (2020), *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*, Advances in Neural Information Processing Systems (NeurIPS).
- [5] Google DeepMind (2023), *Gemini: A Family of Highly Capable Multimodal Models*, Technical Report.
- [6] BAAI (2024), *BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*, arXiv preprint.
- [7] Chroma (2024), *Chroma Documentation - the AI-native open-source embedding database*, <https://docs.trychroma.com>.
- [8] Weights & Biases (2024), *Developer Documentation*, <https://docs.wandb.ai>.